



已实现 | DQ 非对称 Actor-Critic: M0 / M1 / M2

默认 M2 = M1 + 传感器 belief; M0 / M1 可切换。蓝: 部署观测 绿: 继承网络 紫: 新增模块 红: 训练专用
训练打包 [priv1276, images62208, task5?, belief16?]: M0 = 63484, M1 = 63489, M2 = 63505

Actor | 所有模式均只使用部署可得输入; 与 Critic 参数独立




Critic | 仅训练; 保留自身 GT 编码器与 GFM; 不读取图像



已实现 | 教师权重直接迁移 → 非对称 PPO

从第一轮 rollout 起，Actor 就只接收部署输入。新增 adapter 为零初始化；已有视觉权重完整继承。

权重迁移 | 源：TeacherVisionPolicy / 原教师 Critic



直接 PPO | 模式可切换 M0 / M1 / M2 (默认)

完整 rollout → GAE → PPO
更新 Actor 和 Critic
冻结原低层控制策略
保持原任务奖励 / 课程

定期独立评估
Actor 取均值动作
按任务成功率选择 checkpoint

部署导出 v2
纯 Actor + 61维归一化统计
feature flags + belief约定
M2: 图像62208 + raw61 + belief16

迁移与恢复边界
初始化：恢复原归一化统计，新建 PPO optimizer
恢复训练：严格读取相同模式的 v2 checkpoint
部署输入无需1276维 GT，也无需任务记忆5

冻结原输入 / 价值统计

已实现 | M2 传感器感知与 PPO 训练闭环

M2 默认包含 M1。感知估计来自相机帧、标定、采样时间与机器人位姿；GT 只流向 Critic 和训练奖励。
每轮流程：传感器观测 → 执行动作 / 收集 rollout → PPO 更新 → 下一轮观测。

可部署传感器前端 | M2 启用；M0 / M1 直接沿用原图像历史

